Curso: 21710120 - GESTION DE DATOS EN MODELOS DE INTELIGENCIA ARTIFICIAL

Estudiante: David Francisco Gil Castaldo, CE: 607688

Fecha: Diciembre de 2025

Institución: Sena

AA2-EV02 – Informe de segmentación y evaluación de clientes mediante PCA y K-Means – Quantum Retail

Introducción

La empresa Quantum Retail está próxima a lanzar su nuevo producto de audio inmersivo “Aura Pro” y necesita planear campañas de marketing dirigidas a grupos de clientes con perfiles parecidos. Hacer una campaña igual para todos sería costoso y poco eficiente, por eso es importante identificar segmentos de clientes que puedan recibir mensajes y ofertas adaptadas a sus características.

En este informe se describe el proceso que seguí para evaluar y segmentar a los clientes a partir del dataset de Quantum Retail. Primero reduje la cantidad de variables usando Análisis de Componentes Principales (PCA) y después apliqué el algoritmo de clustering K-Means sobre esos componentes. Con los segmentos obtenidos construí perfiles sencillos de cada grupo y planteé algunas recomendaciones iniciales de marketing basadas en esas diferencias.

1. Preparación de los datos

Para este trabajo partí de los resultados de la evidencia AA2-EV01. En esa etapa elegí 10 variables numéricas del dataset original y las estandaricé con StandardScaler para que todas quedaran en una escala comparable, con media cercana a 0 y desviación estándar alrededor de 1. Luego apliqué PCA sobre la matriz ya escalada y revisé la varianza explicada acumulada por cada componente.

El gráfico de varianza explicada acumulada mostró que los primeros nueve componentes principales explican aproximadamente el 91% de la variabilidad total del dataset, lo que está dentro del rango recomendado de 85–95%. Por eso decidí quedarme con 9 componentes. Con eso armé un nuevo conjunto de datos reducido, llamado df_pca, con tamaño 1000 × 9 (1000 clientes y 9 columnas PC1…PC9), que es el que utilicé como base para la fase de clustering.

2. Identificación del número óptimo de clústeres (método del codo)

Para elegir cuántos segmentos usar, apliqué el método del codo sobre el dataset con los componentes principales. Corrí K-Means para valores de k entre 1 y 10 y, en cada caso, guardé la inercia (WCSS) de los clústeres. Con esos resultados armé un gráfico de líneas donde en el eje X está el número de clústeres y en el eje Y la inercia.

En la gráfica se ve que la inercia baja bastante al pasar de k = 1 a k = 3, pero a partir de k = 4 la curva se hace más suave y la mejora es cada vez menor. Este patrón indica que el "codo" está alrededor de k = 3, es decir, ahí se logra un buen equilibrio entre la complejidad del modelo y qué tan compactos quedan los grupos. Por eso tomé k = 3 como número de segmentos para el modelo.

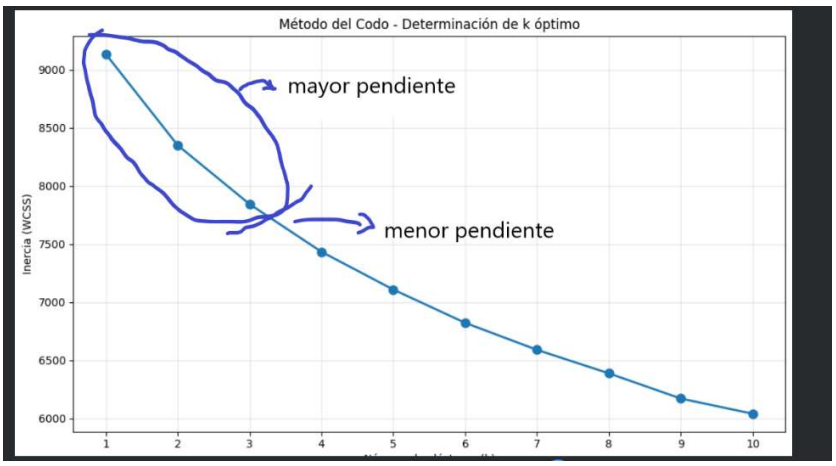

3. Construcción del modelo de clustering y asignación de etiquetas

Con k = 3 entrené el modelo final de K-Means usando como entrada el DataFrame df_pca. El algoritmo asignó a cada cliente una etiqueta de clúster (0, 1 o 2), de esta forma cada registro quedó asociado al grupo al que más se parece según sus características.

La distribución de clientes por segmento fue: clúster 0 con 356 registros (35,6%), clúster 1 con 349 registros (34,9%) y clúster 2 con 295 registros (29,5%). Estos tamaños son parecidos, lo que ayuda a analizar los grupos sin que uno sea demasiado pequeño o domine al resto.

Después añadí la etiqueta de clúster al DataFrame original quantum_customer_data.csv. Así, cada cliente mantiene sus variables de negocio (como Age, AnnualIncome, SpendingScore, WebVisits, etc.) y, además, la columna Cluster, lo que permite interpretar los segmentos usando variables que el equipo de marketing entiende con facilidad.

4. Análisis y caracterización de los segmentos

Para entender mejor qué representa cada clúster, calculé estadísticas descriptivas (como media, mediana, mínimos y máximos) de las variables originales por segmento. Además, generé diagramas de caja y gráficos de barras para comparar cómo se distribuyen Age, AnnualIncome, SpendingScore, WebVisits, EmailsOpened, AdClicks y otras variables importantes en los tres grupos.

Estos gráficos permiten ver rápidamente qué clúster tiene clientes más jóvenes o mayores, quiénes tienen ingresos más altos, quiénes interactúan más con los canales digitales y quiénes muestran mayor interés en las campañas de marketing. Con esta información es posible empezar a construir los perfiles de cada segmento y pensar en que mensajes y ofertas se les puede ofrecer a cada uno.

4.1 Segmento 0 – Clientes de alto valor en riesgo de dejar la marca

El segmento 0 reúne a 356 clientes, que representan el 35,6% del total. En promedio se caracterizan por:

- Ingresos anuales altos, los más elevados de los tres clústeres.
- Un SpendingScore también por encima de los otros segmentos.
- Muchos días desde la última compra, lo que indica menor recencia.

- Un nivel de interacción digital medio-alto: visitan la web, abren correos y hacen clic en anuncios con cierta frecuencia.

- Un tamaño de carrito intermedio, alrededor de 6 productos por compra.

En conjunto, este grupo está formado por clientes con gran capacidad de gasto y que históricamente han comprado bien, pero que últimamente se han alejado de la marca. Son muy valiosos para el negocio, pero muestran señales de posible abandono, por lo que conviene tratarlos con acciones de reactivación específicas (ofertas personalizadas, beneficios exclusivos o campañas de "te extrañamos") antes de que se vayan definitivamente.

4.2 Segmento 1 – Clientes fieles y muy activos

El segmento 1 incluye a 349 clientes, es decir, el 34,9% del total. En las métricas analizadas se observa que:

- Tienen un ingreso anual medio, menor que el del segmento 0 pero suficiente para mantener un nivel de compra constante.

- Su carrito de compra (ItemsInCart) es mayor en comparación a el resto de los grupos.

- Los valores de DaysSinceLastPurchase son bajos, es decir, han comprado hace poco tiempo (alta recencia).

- Presentan una interacción digital fuerte: visitan la web con frecuencia, abren una importante cantidad de correos y responden bien a los anuncios y mensajes en redes.

Estos clientes no tienen los ingresos más altos, pero son muy activos en nuestros canales digitales. Pasan tiempo en nuestra web, están activos en redes sociales, abren nuestros correos electrónicos, y lo más importante es que compran en volumen. Sus carritos son casi el doble de grandes que los otros segmentos.

Para este grupo, la recomendación es una estrategia de bundling y ofertas combinadas. Podemos vender los Aura Pro con accesorios complementarios, hacer descuentos por volumen, y dirigirnos a ellos a través de email y redes sociales, donde sabemos que están muy activos.

4.3 Segmento 2 – Compradores de bajo valor y carrito pequeño

El segmento 2 incluye 295 clientes (29,5%). Su perfil promedio es:

- AnnualIncome más bajo de los tres clústeres.
- SpendingScore parecido al del segmento 1, pero con carritos más pequeños (ItemsInCart en torno a 3 productos).
- Días desde la última compra en un nivel intermedio entre los segmentos 0 y 1.
- Interacción digital aceptable: número de visitas y tiempo de sesión comparables a los otros clústeres, aunque con menos nivel de interacciones en redes sociales.

En conjunto, este es un grupo de clientes de menor valor económico y con compras de bajo volumen. Usan los canales digitales, pero en general realizan transacciones más pequeñas y algo más espaciadas, por lo que pueden ser un buen objetivo para campañas que intenten aumentar el tamaño del carrito y la frecuencia de compra sin requerir un nivel de personalización tan alto como en los segmentos de mayor valor.

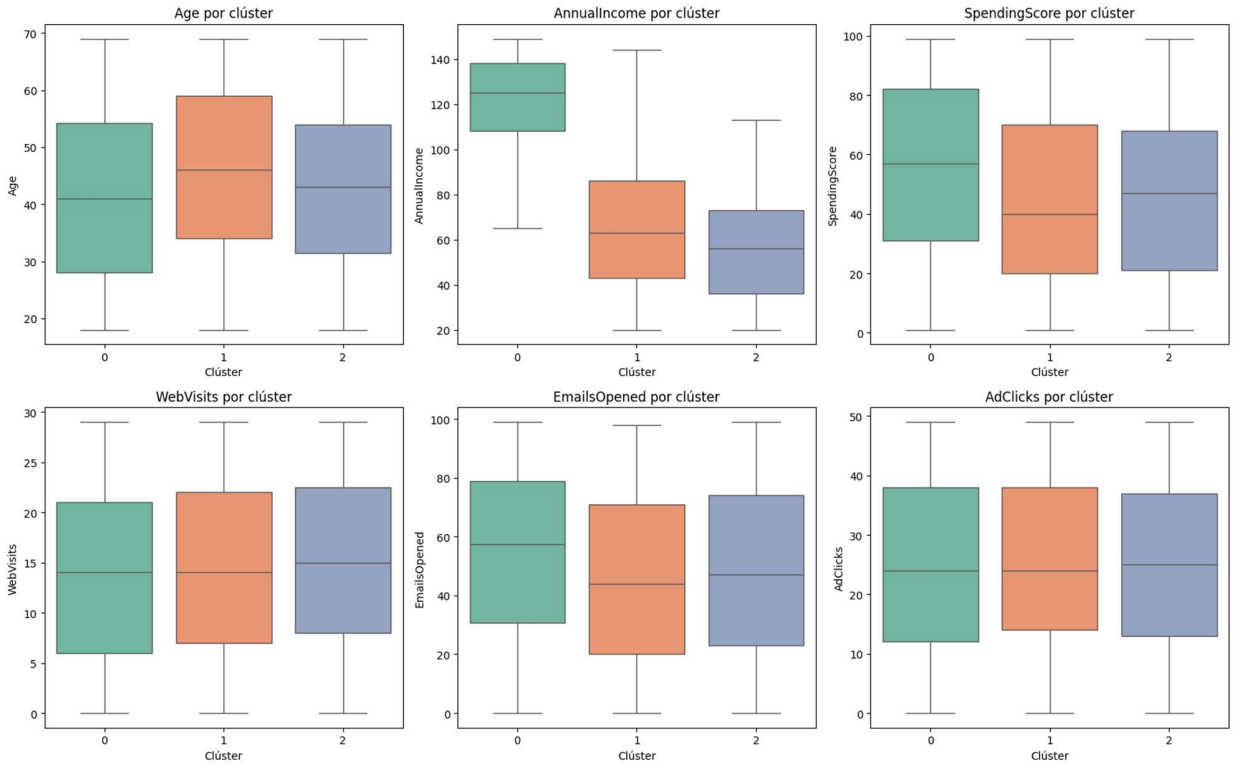

Medias de las variables por cluster.

5. Recomendaciones iniciales de marketing

A partir de las características encontradas se proponen las siguientes acciones iniciales de marketing para cada segmento:

- **Segmento 0 – Clientes de alto valor en riesgo de dejar la marca**
  Diseñar campañas de reactivación específicas, como ofertas exclusivas, acceso anticipado a los auriculares "Aura Pro" o programas VIP que premien su historial de gasto. Es importante reducir el tiempo desde la última compra y recuperar su frecuencia de consumo aprovechando la alta capacidad de gasto que tienen.

- **Segmento 1 – Clientes fieles y muy activos**
  Implementar estrategias de bundles y ventas cruzadas en los canales digitales, destacando complementos de "Aura Pro" (accesorios, garantías extendidas, servicios adicionales). Por su alto nivel de interacción online, pueden aprovecharse campañas personalizadas por email, redes sociales y anuncios segmentados, al igual que programas de puntos por volumen de compra.

- **Segmento 2 – Compradores de bajo valor y carrito pequeño**
  Enfocarse en ofertas de entrada, descuentos por primera compra de "Aura Pro" o versiones más básicas del producto. También podrían inclinarse por promociones de precio y paquetes de bajo costo que incrementen ligeramente el tamaño de su carrito sin implicar un gran esfuerzo económico.

Conclusiones

La combinación de PCA y K-Means permitió simplificar el conjunto de datos de clientes de Quantum Retail y, al mismo tiempo, encontrar tres segmentos con comportamientos claramente diferentes. Al aplicar PCA se trabajó sobre un espacio de características más compacto y con menos redundancia, conservando alrededor del 91% de la varianza original, lo que hizo más estable y manejable el modelo de clustering.

El análisis de los segmentos mostró: un grupo de clientes de alto valor que presenta riesgo de dejar la marca, un segmento de compradores muy activos en canales digitales y con buen nivel de gasto, y un conjunto de clientes de menor valor con carritos más pequeños. Estas diferencias abren la puerta a estrategias de marketing específicas para cada grupo y ofrecen una base sólida para mejorar el retorno de la inversión en la campaña de lanzamiento de "Aura Pro". La segmentación desarrollada en este trabajo

se convierte de esta manera en un insumo importante para apoyar decisiones de marketing basadas en datos dentro de la organización.