Curso: 21710120 - GESTION DE DATOS EN MODELOS DE INTELIGENCIA ARTIFICIAL
Estudiante: David Francisco Gil Castaldo, CE: 607688
Fecha: Noviembre de 2025
Institución: Sena

AA1-EV03. INFORME TÉCNICO DE PREPROCESAMIENTO Y MODELAMIENTO DE DATOS

ÍNDICE

1. Introducción
2. Diagnóstico del Dataset
   2.1. Diccionario de Datos
3. Plan de Limpieza y Transformación
4. Estrategia de Normalización / Estandarización
5. Estructura Final del Dataset
6. Conclusión

1. INTRODUCCIÓN

El presente informe tiene como objetivo detallar el proceso de preprocesamiento y transformación aplicado al conjunto de datos customersatisfactiondata.csv. Este conjunto contiene información de clientes y sus interacciones con un servicio, con el propósito de preparar los datos para el desarrollo de un modelo de regresión que prediga la variable SatisfactionScore.

Se describe el diagnóstico inicial del dataset, la identificación de problemas de calidad en los datos, y se plantea el plan de limpieza y transformación basado en técnicas expuestas en el tutorial proporcionado. Finalmente, se presenta la estructura del conjunto de datos lista para el entrenamiento del modelo de predicción.

2. DIAGNÓSTICO DEL DATASET

El análisis inicial del conjunto de datos customersatisfactiondata.csv reveló que contiene 1000 registros y 8 variables: CustomerID, Age, PlanType, MonthlyBill, HoursWatched_Last30d, SignupDate, CustomerCode y LastSupportTicket.

El tipo de datos es variado, con variables numéricas (enteros y flotantes), categóricas (texto) y fechas en formato string.

Se identificaron varios problemas de calidad en los datos:

- Inconsistencias en la variable PlanType, donde se encontraron múltiples formatos para la misma categoría, p.ej., Premium, premium, PREM.
- Valores faltantes en la variable MonthlyBill, afectando aproximadamente al 15% de los registros.
- Presencia de valores atípicos en Age, con extremos improbables como edades de 0 y 145 años.
- Fechas en la variable SignupDate con formato variado, lo que dificulta su análisis directo.

Esta exploración permitió definir un plan de limpieza y normalización para garantizar la calidad y consistencia de los datos antes del modelado.

2.1 DICCIONARIO DE DATOS

Nombre variable	Tipo dato original	Tipo variable modelo	Descripción y problemas detectados
CustomerID	Texto (string)	Identificador nominal	Identificador único del cliente. Sin valores nulos.
Age	Entero	Numérica continua	Edad del cliente. Se detectaron valores atípicos (0 y hasta 145 años), truncados entre 10 y 100 para evitar sesgos.
PlanType	Texto (string)	Categórica nominal	Tipo de plan del cliente. Presentaba inconsistencias en formato y mayúsculas; unificado y codificado con etiquetas numéricas.
MonthlyBill	Flotante	Numérica continua	Factura mensual pagada. Contiene valores nulos (~15%), imputados con la mediana. Distribución con outliers, normalizada entre 0 y 1.
HoursWatched_Last30d	Flotante	Numérica continua	Horas visualizadas en últimos 30 días. Variable limpia, con algunos outliers; normalizada entre 0 y 1.
SignupDate	Texto (string)	Fecha	Fecha de alta en formatos heterogéneos. Convertida a tipo datetime para facilitar análisis temporal.
LastSupportTicket	Texto (string) libre	Texto libre / cualitativa	Contenido del último ticket de soporte enviado, texto abierto con alta variabilidad, sin transformación específica para modelado.

3. PLAN DE LIMPIEZA Y TRANSFORMACIÓN

Para abordar las inconsistencias y problemas hallados durante el diagnóstico, se aplicaron las siguientes transformaciones basadas en las técnicas descritas en el tutorial del curso:

- Unificación y limpieza de la variable PlanType: Todos los valores fueron convertidos a minúsculas y se eliminaron espacios en blanco para normalizar las categorías. Se corrigieron abreviaturas y variantes erróneas, asegurando una codificación consistente que facilita el análisis posterior.

- Conversión de la variable SignupDate al formato datetime: Dada la heterogeneidad en los formatos de fecha presentes, se aplicó una función que intenta interpretar las fechas en diferentes formatos para convertirlas en un tipo datetime estándar, permitiendo su uso eficiente en análisis temporales y creación de nuevas variables.

- Manejo de valores atípicos en Age: Se establecieron límites mínimos y máximos razonables (10 y 100 años, respectivamente, para truncar los valores extremos que podrían distorsionar el aprendizaje del modelo (de contar con más información sobre la naturaleza del servicio podría ajustarse mejor el mínimo).

- Imputación de valores nulos en MonthlyBill: Se sustituyeron los valores faltantes por la mediana de esta variable para mantener la integridad del conjunto de datos sin sesgar la distribución debido a la presencia de valores extremos.

- Codificación de PlanType: se empleó la codificación por etiquetas numéricas (label encoding), asignando valores enteros según la jerarquía de los planes ofrecidos por la empresa: básico = 0, estandar = 1 y premium = 2. Esta técnica se justifica porque existe una relación ordinal reconocida entre los tipos de plan, donde el plan premium representa el nivel más alto de beneficios y costo, el plan estándar un nivel intermedio, y el plan básico el nivel más bajo. De este modo, el modelo de regresión puede aprovechar esta información para estudiar cómo la progresión entre los planes influye en variables como la satisfacción del cliente o el monto facturado mensual.

4. ESTRATEGIA DE NORMALIZACIÓN / ESTANDARIZACIÓN

Tras analizar la distribución de las variables numéricas relevantes MonthlyBill y HoursWatched_Last30d, se observa que presentan rangos amplios y numerosos valores atípicos en los extremos superiores.

Por esta razón, se recomienda aplicar una técnica de normalización que escale los valores al rango, reduciendo el impacto de los outliers y facilitando la convergencia del modelo de regresión.

La estandarización, aunque útil en otros contextos, podría verse afectada por los outliers presentes si no se realiza un tratamiento adicional.

Por tal razón, el procedimiento adoptado consistirá en aplicar normalización min-max a las variables numéricas, de acuerdo con las técnicas indicadas en el tutorial.

5. ESTRUCTURA FINAL DEL DATASET

Luego de aplicar las técnicas de limpieza, transformación, imputación, codificación y normalización descritas, el conjunto de datos quedó conformado para su uso en el modelo de regresión con las siguientes variables:

- CustomerID: Identificador único del cliente, tipo string.
- Age_clean: Edad del cliente, variable numérica entera, con valores truncados entre 10 y 100 para evitar outliers.
- PlanType_label: Variable categórica codificada como etiqueta numérica para representar el tipo de plan del cliente.
- MonthlyBill_clean: Factura mensual, variable numérica normalizada entre 0 y 1 tras imputar valores faltantes con la mediana.
- HoursWatched_Last30d: Número de horas visualizadas en los últimos 30 días, también normalizada en el rango.
- SignupDate_clean: Fecha de alta en formato datetime estándar, lista para análisis temporal o extracción de nuevas características.
- LastSupportTicket: Texto libre con contenido del último ticket de soporte enviado por el cliente, variable cualitativa.
- Antiguedad_Cliente: Como parte del preprocesamiento se creó esta nueva variable, calculada a partir de la diferencia entre la fecha actual y la fecha de alta del cliente (SignupDate_clean). Esta columna expresa la antigüedad en meses desde el momento del registro del cliente en el servicio. La inclusión de esta variable permite al modelo de regresión analizar el impacto del tiempo de permanencia en la satisfacción, en el consumo y en otras variables de interés, mejorando la capacidad explicativa y predictiva del modelo.

6. CONCLUSIÓN

Realizar con rigurosidad la etapa de modelamiento y preprocesamiento de datos en proyectos de inteligencia artificial permite detectar patrones reales, evitar sesgos y asegurar que el modelo aprenda de información relevante y representativa. Ignorar la importancia de la limpieza y el modelado de datos puede llevar a modelos ineficaces, poco útiles e incluso a conclusiones erróneas que afectan la gestión del negocio.

En conclusión, invertir tiempo y esfuerzo en el preprocesamiento y modelamiento de datos no es sólo una buena práctica técnica, sino una condición indispensable para obtener soluciones de IA que realmente generen valor y confianza.